Clasificador Bayesiano: Grooming

Contexto.

Una organización que gestiona una plataforma de mensajería quiere implementar un sistema automático para detectar posibles casos de grooming (acoso a menores en línea) a partir de mensajes de texto enviados por los usuarios.

Objetivo:

Entrenar un modelo de clasificación Naive Bayes con un conjunto de mensajes etiquetados como grooming o no grooming, evaluar su rendimiento y usarlo para identificar mensajes sospechosos en tiempo real.

Datos

Mensaje	**Etiqueta**
¿Cuántos años tenés? No le digas a nadie que hablamos.	grooming
Hola, ¿cómo estás? ¿Querés jugar algo online?	no grooming
Sos muy linda, no le muestres esto a tus papás.	grooming
¿Terminaste la tarea de matemáticas?	no grooming
Podés mandarme una foto tuya, pero que sea solo para mí.	grooming
¿Querés que te ayude con el juego que no podías pasar?	no grooming
No le contés a nadie que hablamos por acá, ¿sí?	grooming
¿Te gustó la película de ayer?	no grooming
¿Estás solo en casa ahora?	grooming
¿Querés hacer una videollamada para estudiar juntos?	no grooming
No le digas a tus padres que te escribí, es nuestro secreto.	grooming
¿Cómo te fue en el examen de historia?	no grooming
Mandame una foto tuya, pero que nadie más la vea.	grooming
¿Jugamos Minecraft esta tarde?	no grooming

Sos muy especial para mí, no le cuentes a nadie lo que hablamos.	grooming
¿Querés que te pase los apuntes de biología?	no grooming
¿Podés mostrarme cómo estás vestida ahora?	grooming
¿Tenés ganas de salir a andar en bici mañana?	no grooming
No hace falta que le digas a nadie que hablamos tanto.	grooming
¿Querés que estudiemos juntos para el parcial?	no grooming

EXPLICACIÓN BREVE DEL CÓDIGO.

1. Lectura de ejemplos: El programa utiliza una lista de mensajes de chat donde se le indica cuáles son seguros (no grooming) y cuáles son de riesgo (grooming).

2. Traducción a números (CountVectorizer): El programa convierte las oraciones contando qué palabras aparecen (por ejemplo, detectando términos frecuentes como *"foto"*, *"secreto"*, *"papás"* o *"juego"*).

3. Aprendizaje (Naive Bayes): El modelo calcula la probabilidad de que un mensaje sea peligroso basándose en las palabras que contiene. Aprende a asociar ciertos términos con el riesgo.

4. Evaluación automática: El programa separa una parte de los mensajes para realizar una prueba, predice si son peligrosos o no, y compara su respuesta con los ejemplos del aprendizaje para ver qué tan bien predijo.

Nuevos Mensajes a clasificar

"¿Podes mandarme una foto tuya? No se la muestras a nadie". **Resultado** -> grooming

"¿Jugamos Minecaraft esta tarde?". **Resultado** -> no grooming

"No le digas a tus papas que hablamos, ¿si?". **Resultado** -> grooming

"¿Terminaste el trabajo practico de historia?". **Resultado** -> no grooming

INFORME DEL MODELO DE DETECCIÓN DE GROOMING

1- Precisión del modelo (Accuracy): El modelo obtuvo una precisión del **100%**. Esto significa que, de todas las pruebas que se le hicieron con mensajes nuevos, acertó correctamente todos los casos al distinguir entre un mensaje seguro y uno de riesgo.

2- Reporte de clasificación:

- **Identificación de Grooming:** El modelo consiguió reconocer con éxito las señales de alerta (como pedidos de fotos ocultas o solicitudes de guardar silencio), sin dejar pasar los mensajes peligrosos.

- **Identificación de No Grooming:** Identificó correctamente aquellas charlas inofensivas, tareas escolares o relacionadas a videojuegos, evitando generar falsas alarmas.

Matriz de Confusión:

La matriz de confusión del modelo quedo: [[2, 0], [0, 4]] es decir, analizó un total de **6 mensajes de prueba** en el conjunto de evaluación y obtuvo un **100% de aciertos** (sin ningún error ni falsas alarmas).

- **El 2:** Identificó correctamente los mensajes seguros (`no grooming`) que verdaderamente eran seguros.
- **El 4:** Identificó correctamente los mensajes de riesgo (`grooming`) que verdaderamente eran peligrosos.
- **Los ceros:** Demuestran que el modelo no confundió ningún mensaje seguro como peligroso, ni dejó pasar ninguna señal de alerta (cero falsos positivos y cero falsos negativos en esta prueba).